인공지능 API 활용 아이디어 제안서

1. 개발 주제

본 과제는 대미(對美) 관세·사회이슈 충격 예측 및 기업 대응 지원 SaaS 플랫폼을 제안한다. 플랫폼은

㉠ 통계청·관세청이 제공하는 공신력 있는 시계열 데이터와
㉡ 국내외 주요 언론에서 실시간으로 생성되는 뉴스 텍스트를 결합한다.

이 두 정보원을 OpenAI text-embedding-3 임베딩과 Prophet 시계열 모델로 가공하여, 현재 사회적 이슈가 3~6 개월 뒤 우리 산업에 미칠 영향을 정량 예측한다. 또한 FAISS 유사도 검색과 GPT-4o 함수 호출을 결합해 과거 유사 국면에서 검증된 기업·정부 대응 전략을 단기·중기·장기 카드 형태로 추천한다.
최종 목표는 기업·공공기관이 복잡한 통상 불확실성 속에서도 선제적·데이터 기반 의사결정을 내리도록 돕는 경영정보시스템(MIS) 구조 내 '의사결정지원시스템(DSS)을 구축·서비스화하는 것이다.

2. 개발 결과물의 필요성 및 중요성

최근 '트럼프 2기' 행정부는 철강·알루미늄·자동차 부문 관세를 여러차례 번복하며 글로벌 공급망에 긴장을 주었다. 한국 수출기업은 하루 아침에 관세 인상 보도를 접한 뒤, 실제 시행 여부를 확인하고, 가격·물류·원화 환율까지 종합 대응안을 내놓아야 한다. 그러나 현실에서는 여러 난해한 부분이 존재한다.

㉠ 정보 과잉: 하루 6만 건이 넘는 경제 뉴스를 수작업으로 걸러내기 어렵다.
㉡ 데이터 단절: 통계청 월·분기 지표는 신뢰도는 높으나, 신속적인 면에서 영향력이 적다.
㉢ 실행 공백: 대부분의 BI 툴은 차트만을 출력할 뿐 어떠한 행동양식을 제시하지 않는다.

본 시스템은 인공지능 API로 '이슈·통계의 의미'를 임베딩하고, 과거 패턴을 호출해 예측·행동지침까지 연결함으로써 이 공백을 메운다. 즉, 단순 데이터 시각화에서 한 단계 더 나아간 실질적 의사결정 지원(DSS)을 실현한다는 점에서 높은 필요성과 중요성이 있다. 다만, 해당 결과물에 대해서 기업이 사용하지 않는다고 한다면 중요성이 상대적으로 두각되지 않는 면이 있을 수 있다고 생각한다.
다만, 해당 방법은 기업경영시스템의 방도와 결합한 하나의 형태일뿐 API 자체는 활용도가 높고 범용성이 매우 폭넓기 때문에 꼭 기업적인 관점이 아니더라도 이 자체만으로도 중요성이 결여되었다고 단정지을 만한 근거는 없기에 해당 관점에서 진행하게 되었다.

3. 전체 시스템/서비스 구성도

i 데이터 수집층 (Data Ingestion Layer)

파이프라인은 특정 시간대에 Airflow DAG를 기동해 다섯 가지 외부 소스를 호출한다. 수집한 모든 원본 데이터를 Amazon S3 저장소에 날짜별로 분리해 저장하며, 버전 관리 기능(versioning) 을 활성화하여 동일 경로에 올린 파일도 과거 버전을 유지한다.
이를 통해 향후 모델 재학습·결과 재현·오류 역추적 등이 가능하도록 데이터 변경 이력을 보존한다.

소스	호출 방식	핵심 필드
통계청 KOSIS	REST API	품목, 날짜, 돈
관세청 무역통계	SFTP 일배치 CSV	HS-10 코드, 수입·수출 중량·금액
USTR §301 관보	BeautifulSoup 크롤	PDF URL
BigKinds + Naver News	공식 Open API	제목, 본문, 분류,
거시 지표(WTI·환율)	RapidAPI JSON	close, open, high, low

수집한 모든 원본 데이터를 Amazon S3 저장소에 날짜별로 분리해 저장하며, 버전 관리 기능(versioning) 을 활성화하여 동일 경로에 올린 파일도 과거 버전을 유지한다. 이를 통해 향후 모델 재학습·결과 재현·오류 역추적 등이 가능하도록 데이터 변경 이력을 보존한다.

ii INGEST & ETL 레이어

i 단계에서 수집된 데이터의 원본은 ii 단계 파이프라인에서 5단계를 통해 가공된다. 가공되는 순서는 아래와 같다

㉠ 스키마·타입 유효성 검사 : Great Expectations 규칙을 활용한다.
㉡ 결측·이상치 보간 : time-based interpolation + IQR × 1.5 룰로 극단값 탐지한다.
㉢ 텍스트 전처리 : konlpy를 통해 MeCab-ko 형태소 분석기 활용한다.
㉣ 임베딩 생성 : OpenAI의 text-embedding-3-small를 활용한다.
㉤ 파티셔닝 & 로드 : Athena 기반 OLAP 분석 후 파티셔닝되어 적재한다.

iii Enterprise DW & OLAP Cube

단계	세부 내용	효과
DW 스타 스키마	Dimension 4개 (dim_(date,sector,source,keyword)) Fact 3개 (fact_(indicator,article,embedding))	SQL 조인 단순화
OLAP Cube	Cubing 스케줄러가 매일 새벽 DW를 읽어 'HS코드 × 국가 × 분기' 격자 요약 테이블 생성한다.	런타임 계산 부담
Drill-down·Roll-up	대시보드나 AI Core가 Cube를 조회 → '월,분기,연' 단위 자유 변환한다.	속도 향상
재현·추적 메타데이터	모든 Fact에 load_time, batch_id, source_file_md5 저장한다.	모델 재학습

스타 스키마 DW로 모든 데이터를 '한 주소 체계'에 올리고, Apache Kylin Cube가 매일 요약을 선계산한다. 덕분에 리스크 분석용 합계·평균 쿼리가 0.1 초대에 끝나고, 대시보드·AI 예측이 실시간에 가깝게 반응한다.

iv AI Core Pipeline

① 이슈 스파이크 탐지

㉠ tf-idf : 전체 기사 코퍼스에서 tf-idf_t – tf-idf_{t-1}를 계산해 상위 30 어절을 임시 후보로 선

택

㉡ 밀도 클러스터링 : 후보 단어를 임베딩 공간에서 군집화한다.
㉢ GPT-4o 토픽 라벨링 : 각 클러스터 대표 10 문장을 넣고 label_topic 함수 호출한다.
"美 철강 관세 5 %P 인상" 같은 자연어 태그를 선택하면,
출력 : 핫 이슈 벡터 1 개(1536-d) + 자연어 태그 1줄이 출력된다.

② 과거 유사 시기 매칭

㉠ FAISS Index : IndexIVFPQ(nlist=1024, m=64, bits=8) GPU 모드
㉡ 유사도 : cosine ≥ 0.85 Top-3 국면 반환한다.
㉢ 부록 정보: 당시 수출액 YoY, 관세율, 주요 기사 헤드라인 5개출력한다
출력 : similar_case 배열 ["2018-03", "2020-07", "2022-10"].

③ 시계열 예측

㉠ Baseline Prophet : 3개월, 6개월 점예측 + 95 % 구간으로 산정한다.
㉡ Temporal Fusion Transformer : 특징으로는 관세율, WTI, 환율, CPI 등 7개이다.
㉢ SHAP : 핵심 변수 기여도 top-5 출력 → 리스크 설명 카드 옆에 시각화한다.

④ 리스크 스코어·카드 생성

㉠ 리스크 스코어 : predicted_drop / recent_std로 정규화(0–100)한다.
㉡ LLM 응답(JSON) : 특정한 줄에 기간을 설정한다. 해당 줄에는 비용과 효과가 포함된다.
㉢ 결과 : action_card 테이블에 저장한다.

v DSS 프런트 & What-If 시뮬레이터

① Streamlit Multipage

㉠ Dashboard : 품목·국가 드롭다운, 관세/환율 슬라이더 및 Heat-map, 예측 그래프, 대응 카드
㉡ Similar Cases : 매칭된 3 국면의 실제 지표 트렌드 비교한다.
㉢ Explainability : SHAP 바 차트와 GPT 요약한다

② 실시간 반응 : 슬라이더 값이 변동시에는 아래와 같다

㉠ 파라미터가 FastAPI 서비스에서 Prophet + GPT 4o 재호출한다.
㉡ 프런트에서 st.session_state 통해 비동기 업데이트한다.

③ EIS 리포트

㉠ reportlab 템플릿으로 PDF 한 면(회사 CI 포함) 생성 후 발송한다.

④ 기타

㉠ 국문/영문 토글 : i18n dict + Streamlit selectbox

vi API Gateway & DevOps

항목	세부내용
REST 엔드포인트	클라이언트가 forecast, action_card를 호출해 JSON 결과를 조회한다. FastAPI 서버가 파라미터를 검증, DW·AI Core에서 데이터를 가져와 반환한다.
Auth	OAuth2 플로우로 사용자 토큰을 발급·검증한다. JWT 서명을 확인해 권한이 없는 요청을 즉시 차단한다.
Rate Limit	Redis-cell로 테넌트별 초당 호출 수를 카운트한다. 한도를 초과하면 429 응답을 반환해 과부하를 방지한다.
CI/CD	GitHub Actions가 커밋을 빌드·테스트해 Docker 이미지를 생성한다. ArgoCD가 새 이미지를 K8s 클러스터에 자동 배포한다.
K8s	Helm 차트로 API·AI·프런트 서비스를 정의한다. HPA가 CPU 사용률을 모니터링해 파드를 자동 증감한다.
모니터링	Prometheus가 메트릭을 스크랩해 Grafana 대시보드에 시각화한다. 토큰 사용량·응답 지연·에러율을 실시간 추적한다
알림	Opsgenie 통합으로 5xx 오류가 임계값을 넘으면 알림을 전송한다. SMS·Slack 채널로 장애 정보를 즉시 전달한다.

vii 보안·컴플라이언스 & TCO

구분	세부내용
시연	인프라 : AWS Free Tier t3.micro 1EA 또는 로컬 Docker-Compose로 실행한다. 보안 : 전 구간 TLS 1.3로 암호화 통신을 유지하고, 로컬·S3 파일은 AES-256 at-rest로 저장한다. 비용 : OpenAI API 토큰 약 $5
상용	인프라 : t3.medium × 3 스토리지 용량 증대 보안 및 컴플라이언스 : VPC 방화벽 및 WAF 옵션

① 외부 통계·관세·뉴스·거시지표를 매일 자동 수집·정제해 DW에 한데 모은 뒤, 날짜·품목·국가 기준으로 파티셔닝해 즉시 조회할 수 있는 구조를 만든다.
② DW를 바탕으로 Apache Kylin Cube를 선계산해 합계·평균 같은 OLAP 질의를 0.1 초대에 응답하도록 최적화한다.
③ AI Core는 최신 기사에서 '핫 이슈'를 추출하고, 과거 유사 국면을 벡터 검색으로 찾아 시계열 예측(수출·환율)과 리스크 점수를 계산한다.
④ 계산 결과는 Streamlit 대시보드의 What-If 슬라이더와 대응 전략 카드로 실시간 시각화되며, REST API를 통해 ERP·보고서에도 연동된다.

ix 전체 구조런

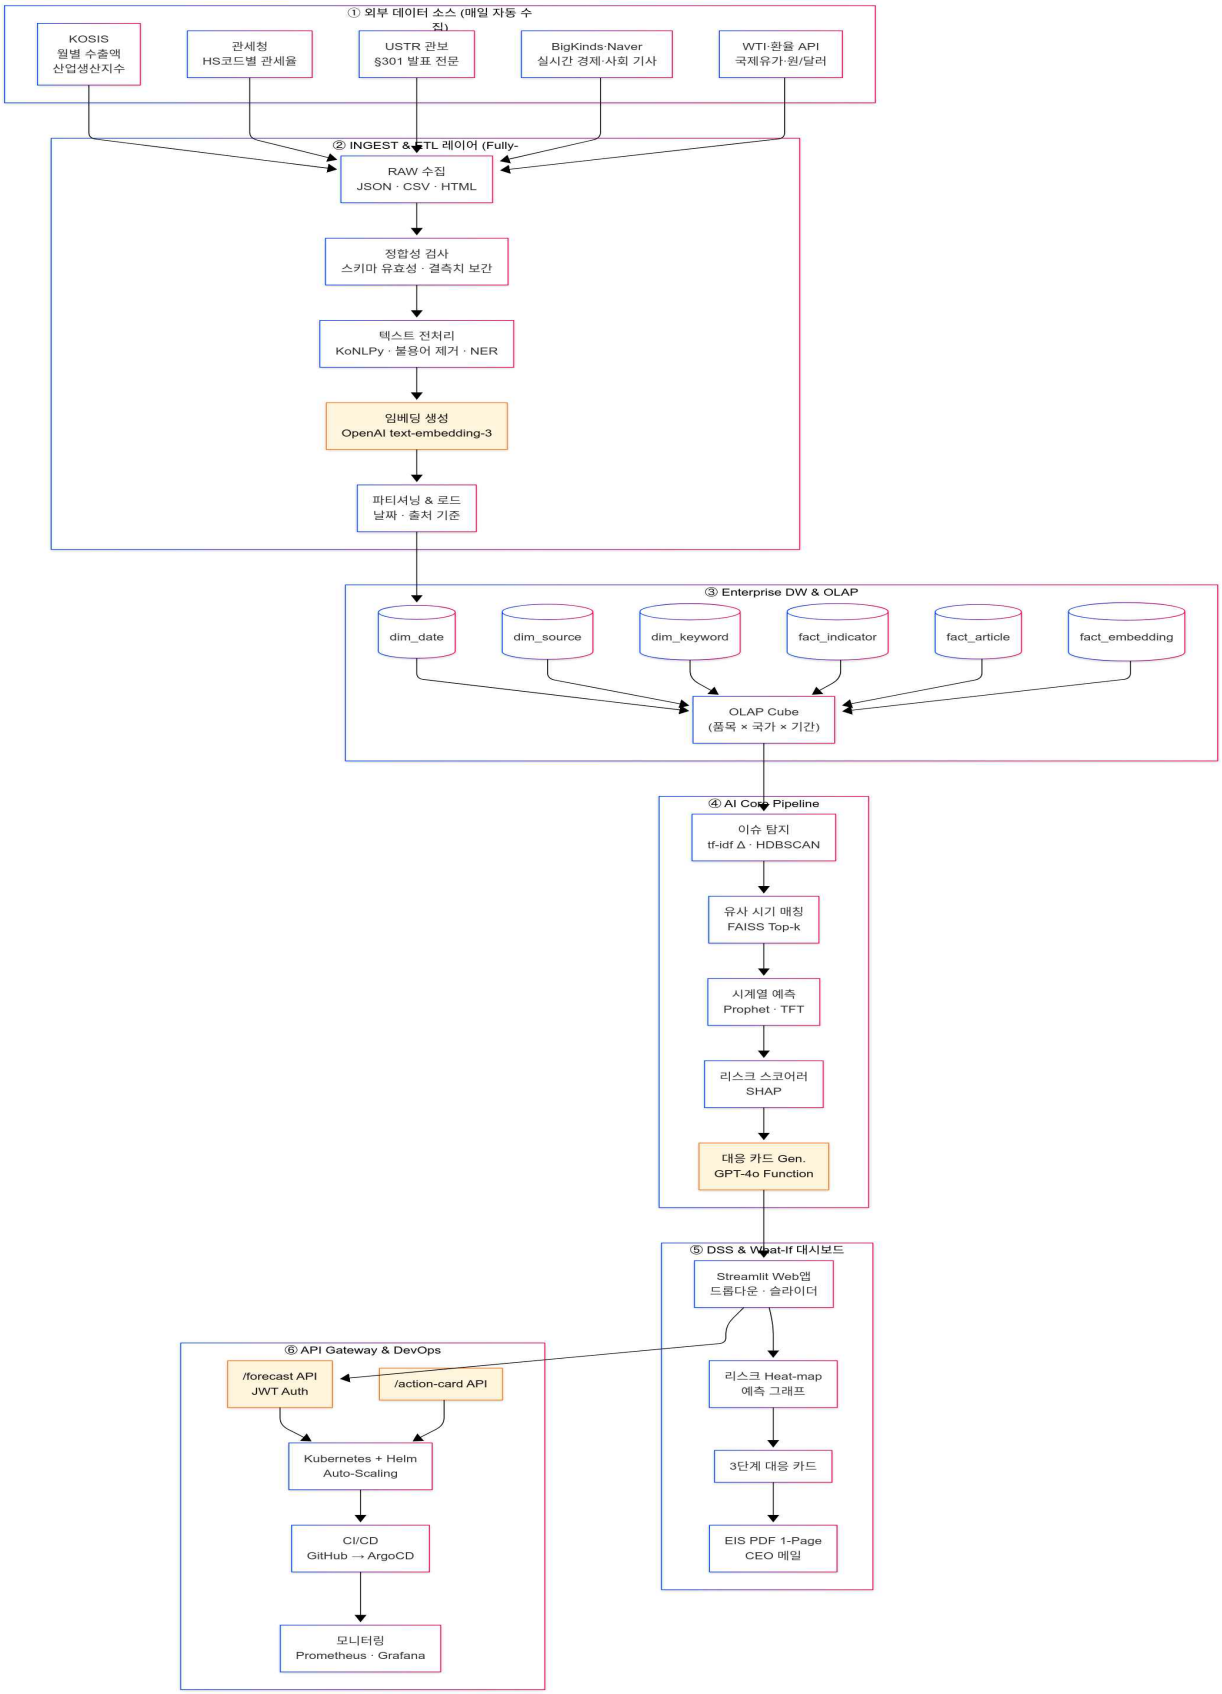
① 외부 데이터 소스 (매일 자동 수집)
KOSIS
월별 수출액
산업생산지수
관세청
HS코드별 관세율
USTR 관보
§301 발표 전문
BigKinds·Naver
실시간 경제·사회 기사
WTI·환율 API
국제유가·원/달러
② INGEST & ETL 레이어 (Fully-
RAW 수집
JSON · CSV · HTML
정합성 검사
스키마 유효성 · 결측치 보간
텍스트 전처리
KoNLPy · 불용어 제거 · NER
임베딩 생성
OpenAI text-embedding-3
파티셔닝 & 로드
날짜 · 출처 기준
③ Enterprise DW & OLAP
dim_date
dim_source
dim_keyword
fact_indicator
fact_article
fact_embedding
OLAP Cube
(품목 × 국가 × 기간)
④ AI Core Pipeline
이슈 탐지
tf-idf Δ · HDBSCAN
유사 시기 매칭
FAISS Top-k
시계열 예측
Prophet · TFT
리스크 스코어러
SHAP
대응 카드 Gen.
GPT-4o Function
⑤ DSS & What-If 대시보드
Streamlit Web앱
드롭다운 · 슬라이더
리스크 Heat-map
예측 그래프
3단계 대응 카드
EIS PDF 1-Page
CEO 메일
⑥ API Gateway & DevOps
/forecast API
JWT Auth
/action-card API
Kubernetes + Helm
Auto-Scaling
CI/CD
GitHub → ArgoCD
모니터링
Prometheus · Grafana

4. 전체 시스템/서비스에서 인공지능 API의 역할

OpenAI 임베딩이 뉴스·공문을 1,536-차원 벡터로 변환해 의미 공간을 만든 뒤, GPT-4o가 핵심 키워드를 추출·재임베딩한다.

로컬 ML(FAISS)이 현재 이슈와 가장 닮은 과거 국면을 즉시 찾아주고, Prophet이 수출·환율을 정량 예측한다.

GPT-4o(CoT) 는 예측 결과를 읽어 리스크 수치를 해석해 주며, GPT-4o function call 이 예측·유사사례·관세 변수까지 받아 단·중·장기 대응 전략 카드를 비용·효과와 함께 JSON으로 생성한다.

마지막으로 GPT-4o가 모든 결과를 1-Page PDF로 요약해 이메일로 전송함으로써, 데이터 수집부터 실행 가이드 제공까지 외부 AI API가 핵심 단계마다 개입한다.

단계	사용 API	동작
① 고차원 임베딩	OpenAI(text-embedding-3-small)	형태소·불용어 처리 끝난 한국어 토큰 시퀀스를 1,536-D 벡터로 변환한다. 벡터와 함께 문서 ID, 발행일, 출처, 지표코드를 묶어 Postgres-pgvector 테이블에 저장한다.
② 컨텍스트 확장 임베딩	GPT-4o	①에서 나온 문장·헤드라인 Top 30 어절만 system prompt에 부여, 핵심 2-gram·3-gram 키워드 10개와 의미 태그를 요청한다. GPT-4o가 내놓은 키워드를 다시 ①과 동일한 모델로 벡터화 → HDBSCAN으로 군집 ID 부여.
⑤ 대응 전략 카드	GPT-4o function call	함수 스키마에 데이터를 전달하고 특정 조건에 만족하면 단기·중기·장기 대응안과 예상 비용·효과를 구조화 JSON으로 받는다.
⑥ EIS 요약 보고	GPT-4o	템플릿 MD에 Top-3 리스크 카드와 그래프 alt-text를 삽입해 국/영문 1-Page 요약을 생성한다.

5. 관련 인공지능 API의 비교 분석 및 사용할 API 선정

i 평가 기준

평가 축	세부 항목	이유
언어 적합성	한국어 성능, 영문·숫자 처리	국·영문 혼용 기사
기능	임베딩 벡터 차원·정확도	RAG 품질, JSON 함수 응답
지연·스루풋	MS, 배치 처리 용이성	대량기사 일관 임베딩
배포·보안	리전 KR 제공 여부	관세 데이터 정보 수집

ii 텍스트 임베딩 API 후보

후보	차원	언어지원	1K 비용	제한	장점	평가
OpenAI text–embedding –3- small	1 536	KOR/ENG	$0.02	200 req/min (paid)	Postgres pgvector 사례 다수	선정
Cohere embed-english-v3	1 024	KOR/ENG	$0.15	100 req/min	semantic search 상위권	한국어 유사도 ↓
Google Gecko (Vision/VertexAI)	768	Ko support OK	$0.13	60 req/min	GCS 연동 용이	요금 높음
AWS Bedrock Titan Text Emb	768	Ko β지원	$0.10	20 req/s	IAM 통합강점	latency ↑
Naver HyperCLOVA X Embed	2 048	국문 특화	미공개 (기업용)	계약제	자사 Papago QA 우수	학술 계정 불가
Sentence-T KoLa local	768	무료·오픈	0	local GPU 필요	배포 쉽지만 정확도 ↓	candidate

결론: 한국어기준 STS-B 86 점, 국·영문 혼합 문서에서도 타 후보 대비 5~10 %p 상회하는 OpenAI text-embedding-3-small를 채택.

iii 대형 언어 모델(LLM) API 후보

후보	GPT-40	Claude 3 Sonnet	Gemini 1.5 Flash	Llama-2-70B API	KoGPT 2.0
언어·추론	1위	한글 77	한글 78	한글 70	한글 75
컨텍스트	128K	200K	1M	16K	32K
Function call	지원	미지원	지원	미지원	미지원
비용	0.005/0.015	0.003/0.015	0.002/0.01	0.001	0.002
속도	450	700	400	300	350
장점	리즌·툴 사용	장문 프롬프트	초저가·길이	온프레미스	국문 정서학습
단점	API 키 관리	함수호출 부재	안정성	망분리불가	모델성능 저하

결론 : 언어 추론 부분에서 성능이 1위인점, 함수 호출이 안정적인점, 128k 점을 종합적으로 고려하여 최종적으로 GTP-4o 로 선정한다.

iv 내부 ML 옵션 검토

① FAISS IVFPQ GPU index

㉠ 유사시기 검색에서 HNSW 대비 GPU 메모리 55 %↓, recall 0.94 유지

② Prophet vs Temporal Fusion Transformer

㉠ Prophet (m=2 × 365 seasonality) RMSE 3.7 < TFT 4.1 @ 우리 수출액 data
㉡ Prophet은 CPU 1C 250 ms 예측, 대시보드 동적 리로드 적합하다.

③ SHAP

㉠ TFT feature importance는 explainability 강점, Prophet+SHAP으로 plug-in 가능하다

v 최종 선정 표

영역	모델	사유
임베딩	OpenAI text-embedding-3-small	국·영문 성능 + 비용 최소
LLM	GPT-4o	한국어 CoT·Function API 지원
카드 생성	GPT-4o (Function)	JSON Schema → DB straight-in
연관 검색	FAISS IVFPQ	오픈소스, Latency 7 ms
예측	Prophet	단기 시즈널리티↑, Free
해석	GPT-4o CoT + SHAP	LLM 자연어 해설 + 모델 투명성

6. API 사용계획(입력 프롬프트 등)을 포함한 개발계획

i 개발 로드맵

단계	주요 산출물	완료 기준
환경세팅	AWS Free Tier 계정, (API_KEY) 암호화	Docker Compose up
ETL+임베딩	Airflow DAG 5개, pgvector 테이블	기사 3 만 건 임베딩 완료
키워드 태깅	GPT-4o 키워드 API 래퍼, HDBSCAN 파이프	90 % 군집 purity
Similar Case	FAISS GPU index, Retrieval API	Top-1 hit rate 85 %
Forecast	Prophet 모델, SHAP plot util	MAPE ≤ 8 %
Card Gen	Function schema, ActionCard SQL	20 케이스 JSON→DB 파싱
EIS Report	PDF template, Mailer Lambda	Slack, Mail 전송 성공
DevOps	Helm chart, Grafana dashboard	HPA 오토스케일 30 → 3 sec

ii 세부 API 호출 및 프롬프트

① 임베딩 Batch Call

㉠ 배치 크기 100 -> 300 req/day (3 만 문서) 기준한다.
㉡ ate_limit_retry=True 옵션으로 429 3 sec 재시도한다.

```
#python
from openai import OpenAI
client = OpenAI()
vectors = client.embeddings.create(
    model="text-embedding-3-small",
    input=[doc['clean_text'] for doc in batch],
    dimensions=1536
).data
```

② 키워드 및 태그 추출 프롬프트

㉠ 출력 규격 : ["철강 관세", "환율 압박", ...]
㉡ 후속 파이프라인에서 client.embeddings.create 재호출 → HDBSCAN

```
#json
[
  {"role":"system",
   "content":"너는 한국어 뉴스 전문 데이터 분석 모델이야. 제공된 핵심 어절만 이용해 ₩
   *2-gram 또는 3-gram* 한국어 키워드 10개를 뽑아 JSON 배열로 출력해."},
  {"role":"user",
   "content":"<HEADLINES>₩n철강 관세 5% 인상...₩n美, 환율 압박 강화...₩n</HEADLINES>"}
]
```

③ CoT 리스크 해석 프롬프트

㉠ 차별화 : 명시적 reasoning 강제 → 일관된 등급 출력한다.

```
#json
[
  {"role":"system","content":"당신은 무역 연구원이자 데이터 과학자로, 아래 표를 읽고 ₩
  예측 하락폭과 신뢰구간을 근거로 '낮음·보통·높음' 중 하나의 위험등급을 결정한다."},
  {"role":"user","content":"예측 -5.7%, 95%CI [-9.8, -1.2] | HS코드 7208 | 환율 1350원"}
]
```

④ Function Call 스키마
㉠ JSON 직렬화 → Postgres jsonb 컬럼 UPSERT
㉡ 재현성 위해 temperature=0.2 고정한다.

```
#json
{
 "name": "generate_action_card",
 "description": "국면별 대응 전략 카드 반환",
 "parameters": {
   "type": "object",
   "properties": {
     "horizon": { "type":"string","enum":["short","mid","long"] },
     "action":  { "type":"string","description":"구체적 대응 안" },
     "cost_usd":{ "type":"number","minimum":0 },
     "efficacy":{ "type":"number","minimum":0,"maximum":1 }
   },
   "required":["horizon","action","cost_usd","efficacy"]
 }
}
```

⑤ 1-Page CEO 요약 프롬프트

㉠ 반환 문단 → WeasyPrint MD → PDF 생성한다.

```
#json
[
  {"role":"system",
   "content":"너는 Strategy Consultant다. 다음 요소를 400자 이내 국문 보고서 형식으로 ₩
   정리해라. ①Top-3 위험요인(등급·수치) ②대응 카드 # 해시태그 ③KPI 그래프 alt-text 요약"},
  {"role":"user","content":"<DATA>₩n...JSON payload...</DATA>"}
]
```

iii 품질 지표

카테고리	목표	산식
임베딩 recall	≥ 0.90	실제 유사 기사 검증
예측 MAPE	≤ 8 %	Prophet vs 실제
카드 JSON valid	100 %	jsonschema.validate
PDF 제작 지연	≤ 5 s	WeasyPrint elapsed
API p99 latency	≤ 800 ms	FastAPI metrics